

Otimização do Sistema de Armazenamento de Energia em Bateria

Edital:	
Grande Área do Conhecimento (CNPq):	Engenharias
Área do Conhecimento (CNPq):	Engenharia Elétrica
Título do Projeto:	Otimização do Sistema de Armazenamento de Energia em Bateria
Título do Subprojeto:	Otimização do Sistema de Armazenamento de Energia em Bateria
Professor Orientador:	Helder Roberto de Oliveira Rocha
Estudante:	Arthur Coelho Estevão Mayke Wallace Silva Alves

Resumo

A otimização do Sistema de Armazenamento de Energia em Bateria (BESS) é fundamental para a integração de fontes renováveis em edificações com consumo líquido de energia zero (ZNEB) e aprimoramento da eficiência do sistema elétrico. Para atingir esse objetivo, o trabalho busca aplicar algoritmos genéticos utilizando o NSGA-III para otimizar o tamanho do BESS, considerando múltiplos objetivos, como maximização da utilização de fontes renováveis e minimização de custos operacionais. Simulações e análises serão realizadas para avaliar o desempenho do algoritmo genético em diferentes cenários, bem como comparar os resultados obtidos com os tamanhos de BESS encontrados por métodos tradicionais. Além disso, o trabalho visa analisar os impactos econômicos da utilização do BESS otimizado e propor diretrizes para sua implementação prática em edificações ZNEB. Com isso, busca-se contribuir para o avanço da tecnologia de armazenamento de energia e promover uma transição mais eficiente e sustentável para sistemas elétricos de baixo carbono.

Palavras-chave: *Algoritmos Genéticos, NSGAIII, Since Battery Energy Storage System (BESS), fotovoltaic (PV), Energy Storage Systems (ESS), Otimização*

1 Introdução

Tradicionalmente, os *synchronous generators* (SG) têm sido a base da operação dos sistemas de energia, devido ao uso de recursos naturais, como carvão e gás natural, e à sua capacidade de despacho total. No entanto, a demanda por eletricidade apresenta altos níveis de variação e flutuação, tornando o consumo não controlável. Nesse cenário, a otimização de processos, como o despacho e a regulação, pode trazer benefícios em um ambiente onde a variabilidade e a inconsistência são comuns. (EL-BIDAIRI; et al; 2020)

Embora o comportamento dos sistemas de energia, que dependem dos SGs, tenha sido amplamente estudado, tecnologias emergentes, como as *nonsynchronous renewable energy sources* (NS-RES), podem e irão desafiar tanto a operação quanto a estabilidade das redes elétricas. Exemplos dessas tecnologias incluem parques eólicos e parques de maré, geração distribuída como telhados *photovoltaic* (PV) e *Energy Storage Systems* (ESS), como o *Since Battery Energy Storage System* (BESS). Essas novas tecnologias representam oportunidades e desafios para a integração e gestão eficiente de energia, impulsionando a busca por soluções inovadoras no setor elétrico. (EL-BIDAIRI; et al, 2020)

O BESS é uma solução comprovada que desempenha um papel fundamental na integração bem-sucedida de fontes de energia renovável nos sistemas elétricos. Sua capacidade de suavizar a potência de

saída das fontes renováveis, como energia solar e eólica, é crucial para lidar com a variabilidade inerente dessas fontes e garantir um fornecimento de energia estável e confiável.(MAHMOUD; 2019)

Além disso, MAHMOUD (2019) destaca que o BESS também desempenha um papel crucial na estabilização dos *microgrids*. À medida que a adoção de *microgrids* cresce, especialmente em comunidades isoladas ou áreas remotas, a presença de sistemas de armazenamento de energia se torna ainda mais vital para garantir o equilíbrio entre a oferta e demanda de energia. A capacidade de armazenar o excesso de energia produzida durante os períodos de maior geração e liberá-lo quando a demanda é maior permite uma operação mais eficiente e autônoma das microrredes.

Além dos benefícios operacionais, o BESS também oferece vantagens econômicas ao sistema elétrico. Ao otimizar a utilização de fontes renováveis e evitar a necessidade de construção de infraestruturas adicionais para lidar com picos de demanda, o custo geral do sistema elétrico pode ser reduzido significativamente.

2 Objetivos

O objetivo geral deste trabalho é aplicar algoritmos genéticos utilizando o NSGA-III para otimizar o tamanho do Sistema de Armazenamento de Energia em Bateria (BESS) em edificações, a fim de buscar edificações com consumo líquido de energia zero (ZNEB), visando maximizar a integração de fontes de energia renovável e melhorar a eficiência operacional do sistema elétrico. Para alcançar esse objetivo, os seguintes objetivos específicos serão atingidos:

- Desenvolver um modelo matemático que represente o comportamento do BESS em relação à potência de saída das fontes renováveis e aos padrões de consumo de energia da edificação ZNEB.
- Implementar o algoritmo genético NSGA-III para otimizar o tamanho do BESS, considerando múltiplos objetivos, como maximização da utilização de fontes renováveis e minimização de custos operacionais;
- Realizar simulações e análises para avaliar o desempenho do algoritmo genético em diferentes cenários, considerando variações nos padrões de geração e consumo de energia;
- Comparar os resultados obtidos com os tamanhos de BESS encontrados pelo algoritmo genético com os tamanhos determinados por métodos tradicionais, destacando as vantagens e eficiência da abordagem proposta;
- Analisar os impactos econômicos da utilização do BESS otimizado, considerando a redução de custos operacionais e a viabilidade financeira da implementação da tecnologia;
- Propor diretrizes e recomendações para a aplicação prática da estratégia de otimização em edificações ZNEB, visando promover a adoção mais ampla de soluções sustentáveis e eficientes baseadas em BESS.

Ao alcançar esses objetivos, o trabalho busca contribuir para o avanço da tecnologia de armazenamento de energia e para o aprimoramento da operação de edificações com consumo líquido de energia zero, promovendo uma transição mais eficiente e sustentável para sistemas elétricos de baixo carbono.

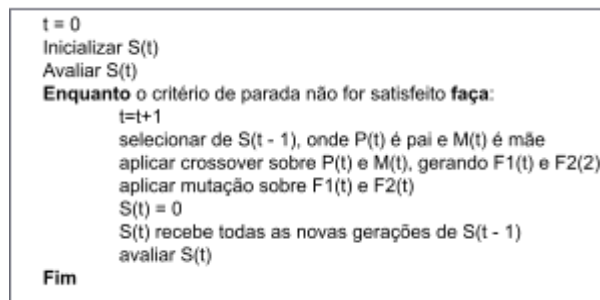
3 Embasamento Teórico

Algoritmo Genético

O algoritmo genético é um método de otimização bio inspirado, desenvolvido por John Henry Holland em 1975. Segundo a teoria evolucionária de Charles Darwin, os seres sofrem mutações e os mais aptos (melhores) vão sobreviver. Então investigar como ocorre tal seleção natural e efetuar simulação permite gerar dados com características desejadas. Neste texto será abordado sobre algoritmos genéticos, usando como exemplo, casos de cromossomos codificados pelos números reais.(Massago, 2013)

O primeiro passo de um Algoritmo Genético típico é a geração de uma população inicial de cromossomos, que é formada por um conjunto aleatório de cromossomos que representam possíveis soluções do problema a ser resolvido. Durante o processo evolutivo, esta população é avaliada e cada cromossomo recebe uma nota (denominada de aptidão no jargão da literatura de AGs), refletindo a qualidade da solução que ele representa. Em geral, os cromossomos mais aptos são selecionados e os menos aptos são descartados (Darwinismo). Os membros selecionados podem sofrer modificações em suas características fundamentais através dos operadores de crossover Figura 2 e mutação Figura 3, gerando descendentes para a próxima geração. Este processo é repetido até que uma solução satisfatória seja encontrada. O algoritmo da Figura 1 ilustra este procedimento.(DE LACERDA;DE CARVALHO, 1999)

Figura 1: Seja $S(t)$ a população de cromossomos na geração



Fonte: Produção do próprio autor

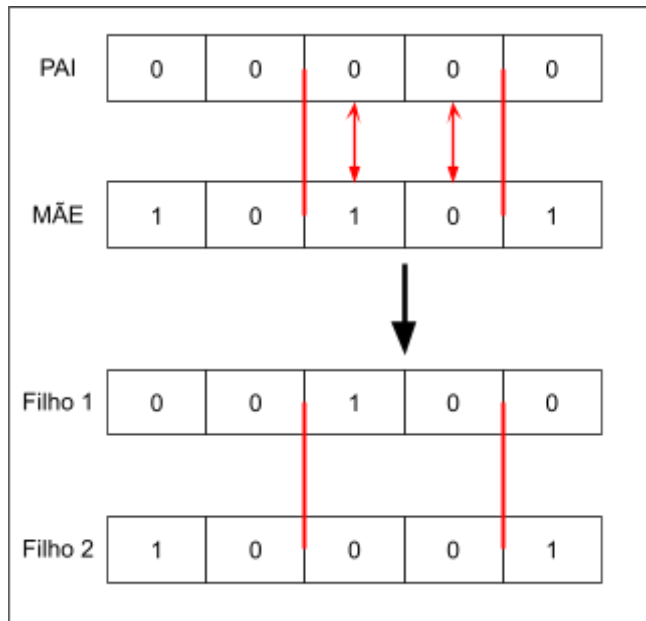
AG's têm sido aplicados a diversos problemas de otimização, tais como: Otimização de Funções Matemáticas, Otimização Combinatorial, Otimização de Planejamento, Problema do Caixeiro Viajante, Problema de Otimização de Rota de Veículos, Otimização de Layout de Circuitos, Otimização de Distribuição, Otimização em Negócios e Síntese de Circuitos Eletrônicos. Alguns exemplos de produtos desenvolvidos no ICA são:

- Fluxo de Caixa Inteligente
- Classificação de Clientes (Data Mining)
- Alocação de Espaço Físico
- Planejamento e Otimização de Embarque de Minério no Porto de Tubarão

- Análise de Alternativas de Investimento em Projetos de Exploração e Prospecção de Petróleo sob Incertezas Técnicas e de Mercado ·
- Otimização da Quantidade e Localização de Poços Petrolíferos para o Desenvolvimento de um Campo de Petróleo sob condições de certeza (PACHECO, 1999)

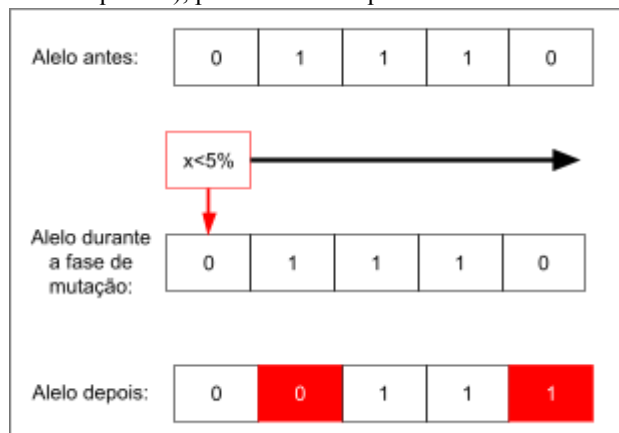
Em resumo, o Algoritmo Genético é uma abordagem poderosa e versátil para a solução de problemas de otimização, oferecendo uma perspectiva interessante baseada na evolução biológica. Ao compreender os princípios teóricos subjacentes a esse método, torna-se possível aplicá-lo de forma eficaz para resolver uma ampla gama de desafios práticos.

Figura 2: Na fase de Mutaç o, aleatoriamente, partes do cromossomo pai e m e trocam informa  es, criando assim o filho 1 e 2



Fonte: Produ  o pr prio autor

Figura 3: Na fase de muta  o, o algoritmo passa por cada bit dos cromossomos filhos fazendo com que exista uma chance, que o autor do algoritmo estipula (n o necessariamente menor que 5%), para fazer com que ele mude.



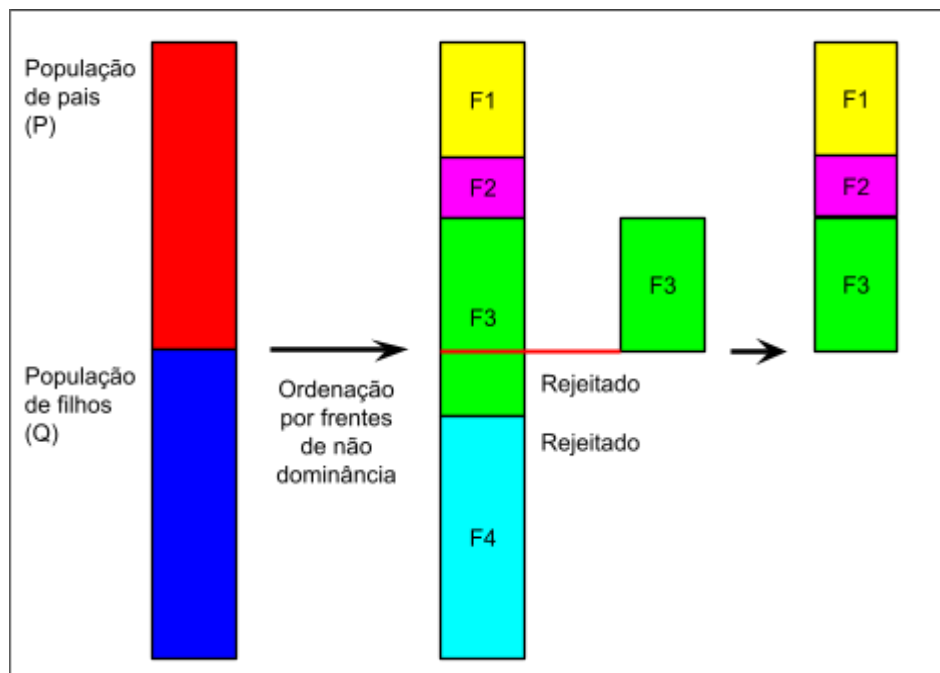
Fonte: Produ  o pr prio autor

NSGA-III

Métodos de otimização evolucionária multi/muitos objetivos (Evolutionary multi/many objective optimization - EMO) surgiram no início dos anos noventa e desde então é crescente a quantidade de pesquisadores nessa área. Impulsionado cada vez mais pela evolução dos computadores, sua popularização também aconteceu na área industrial com o aparecimento de softwares EMO comerciais. No cotidiano os métodos EMO tem demonstrado cada vez mais capacidade para resolver problemas com muitos objetivos. Os métodos de otimização multi/muitos objetivos têm basicamente dois conceitos principais: diminuir a distância entre a frente não dominada e a frente pareto-ótimo e encontrar um conjunto de soluções diversificadas.(Costa; Alves, 2017)

Non-Dominated Sorting Genetic Algorithm (NSGA-III) é um algoritmo genético, evolução do NSGA-II, que busca encontrar a clusterização adequada a sistemas, usando um paradigma de otimização chamado many-objetivo, derivado do paradigma multi-objetivo.(NEVES,2021) O propósito dela é tentar diminuir a complexidade computacional pela técnica de classificação por não-dominância, que faz o elitismo com base em frentes de soluções ditas não-dominadas. O algoritmo Figura 4 trabalha com uma população filha, criada a partir de uma população pai inicial, utiliza um operador de seleção/cruzamento/mutação(AG) e mantém sua diversidade por meio de um mecanismo de preservação de nichos que busca soluções próximas da projeção criada por pontos de referência.(Costa; Alves, 2017)

Figura 4: Fluxo de funcionamento do NSGA-III



Fonte:Produção próprio autor


O gráfico de frente de Pareto

O gráfico de frente de Pareto, também conhecido como gráfico de dispersão da frente de Pareto, é uma ferramenta essencial na análise de problemas de otimização multiobjetivo. Ele representa visualmente as soluções não dominadas encontradas durante a busca por soluções ótimas em um problema com múltiplos objetivos.

Em problemas multiobjetivos, geralmente não existe uma única solução que seja a melhor em todos os objetivos simultaneamente. Em vez disso, há várias soluções que representam diferentes compromissos entre os objetivos. Essas soluções não podem ser melhoradas em um objetivo sem piorar em outro, e são chamadas de soluções não dominadas ou soluções de Pareto.

O gráfico de frente de Pareto mostra essas soluções não dominadas em um espaço de objetivos, Figura 5. Cada ponto no gráfico representa uma solução do problema, onde os eixos são os diferentes objetivos. As soluções não dominadas formam uma curva ou superfície chamada de "frente de Pareto", que representa todas as possíveis soluções ótimas.

Figura 5: Gráfico de dispersão de frente de Pareto



Fonte: Produção próprio autor

4 Metodologia

A pesquisa inicia com uma minuciosa simulação do sistema fotovoltaico (PV) para avaliar o desempenho e a produção de energia do sistema sem a instalação do Sistema de Armazenamento de Energia em Baterias (BESS). Essa análise permite uma comparação direta entre o sistema PV isolado e o sistema com BESS, possibilitando entender os custos relacionados ao PV sem o BESS.

O foco da pesquisa não é dado ao modelo de degradação da bateria, uma vez que os cálculos utilizados para otimização do sistema BESS levam em consideração o custo total da bateria, onde o estado de vida da bateria é otimizado para ser utilizado ao máximo contendo 0.8, representando a bateria no estado final de vida, independente da capacidade do BESS.

Após a etapa de simulação e análise, será detalhado o modelo matemático para a otimização operacional do BESS. Esse modelo tem como objetivo maximizar o aproveitamento da energia armazenada, reduzir custos operacionais e garantir o melhor desempenho do sistema como um todo.

4.1 Sistema fotovoltaico (PV)

Optou-se por utilizar um algoritmo para simular dados de geração solar em uma residência, uma vez que não se dispunha de informações reais de um sistema de geração instalado. Essa simulação foi realizada com base em dados meteorológicos da região de Vitória no ano de 2017, fornecendo uma estimativa de geração caso fosse instalado um sistema de placas fotovoltaicas PV naquela área.

Para realizar essa simulação, considerou-se o consumo médio diário de energia dos 1000 edifícios analisados, sendo calculado o consumo Wh/dia de energia dos edifícios em razão da potência de 610 W da placa WS610M12-60H/BF utilizada em um período de exposição diária de 12H, Equação 1, resultando em um total de 1417 placas necessárias durante o período de consumo. As especificações da placa utilizada podem ser encontradas na Tabela 1.

$$NPaineis = \frac{consumo_{Wh/dia}}{Potência_{placa} \times h} \quad (\text{Equação 1})$$

Tabela 1: Especificações da placa WS610M12-60H/BF


Especificação	Unidade	Valor
Imppt	corrente no ponto de máxima potência (A)	17.46
Vmppt	tensão no ponto de máxima potência (V)	33.94
Not	temperatura nominal de operação da célula (oC)	45
Isc	corrente de curto circuito da célula (A)	15.74
Voc	tensão de circuito aberto do módulo (V)	42.34
Ki	coeficiente de corrente/temperatura (A/ oC)	0.046
Kv	coeficiente de tensão/temperatura (V/ oC)	-0.266
R_{NOCT}	irradiância total (W/m^2)	800
τ_a	produto da transmitância-absortância (p.u)	0,9
η_c	eficiência de conversão do módulo (%)	21,6

Fonte: Produção próprio autor.

Com base nessas informações, foi possível calcular a potência dos painéis fotovoltaicos em cada instante de tempo. Para calcular os valores de potência é necessário determinar a temperatura dos painéis, logo, optou-se por utilizar a equação proposta por YANG, et al. (2018), conforme descrito na Equação 2. Os dados de radiação solar, temperatura e velocidade do vento foram obtidos pelo portal do INMET para a região de Vitória. As medições do dia 1º de janeiro de 2017 podem ser visualizadas nas Figuras 6, 7 e 8, fornecendo uma visão simplificada das condições climáticas durante esse período.


$$T_c = T_a + \left[\frac{\text{radiação}}{R_{NOCT}} \times \left(\frac{9,5}{5,7 + 3,8 \times \text{velocidade}_{\text{vento}}} \right) \times (NOT - 20) \times \left(1 - \frac{\eta_c}{\tau_a} \right) \right] \quad (\text{Equação 2})$$

Figura 6: Radiação por hora no dia 01 de Janeiro de 2017, em Vitória




Fonte: Produção próprio autor.

Figura 7: Temperatura por hora no dia 01 de Janeiro de 2017, em Vitória



Fonte: Produção próprio autor.

Figura 8: Velocidade do vento por hora no dia 01 de Janeiro de 2017, em Vitória



Fonte: Produção próprio autor.

As Equações 3 e 4 são fundamentais para calcular a potência elétrica produzida pelos painéis e dependendo apenas de fatores como o coeficiente de corrente de curto-circuito (I_{sc}) e tensão de circuito aberto (V_{oc}), o coeficiente de temperatura de corrente e tensão, (K_i) e (K_v) respectivamente e a temperatura dos painéis (T_c), formulada anteriormente.

$$I = \text{radiação} \times (I_{sc} + K_i \times (T_c - 25)) \quad (\text{Equação 3})$$

$$V = V_{oc} - K_v \times (T_c - 25)) \quad (\text{Equação 4})$$


$$FF = \frac{V_{mppt} \times I_{mppt}}{V_{oc} \times I_{sc}} \quad (\text{Equação 5})$$

Já o Fator de Forma (FF) Equação 5, é uma medida essencial para avaliar a eficiência dos painéis fotovoltaicos e é calculado com base em parâmetros fundamentais, como a tensão máxima de potência (V_{mppt}), a corrente máxima de potência (I_{mppt}), a tensão de circuito aberto (V_{oc}) e a corrente de curto-circuito (I_{sc}).

$$PotPVM = NPaineis \times FF \times V \times I \quad (\text{Equação 6})$$

Com base nas equações apresentadas, podemos formular a expressão que descreve a potência do sistema fotovoltaico (PotPVM) em cada instante de tempo, Equação 6. Essa equação é fundamental para calcular a quantidade de energia elétrica gerada pelos painéis fotovoltaicos em diferentes momentos, fornecendo informações essenciais para a criação de uma dataframe com os dados de geração no período completo do ano de 2017, as gerações do dia 1º de janeiro de 2017 podem ser visualizadas na Figuras 9.

Figura 9: Geração fotovoltaica por hora no dia 01 de Janeiro de 2017, em Vitória



Fonte: Produção próprio autor.

4.2 Modelo de Bateria

Neste estudo, foram utilizados atributos de referência da bateria Megapack da Tesla, incorporando todas as suas especificações conforme listadas na Tabela 2. Isso permitiu a modelagem do sistema e a análise de seus custos. O investimento relacionado à bateria foi de 2,669,050\$, resultando em um custo estimado de 0.684372 \$/Wh para cada unidade de armazenamento de bateria.

Com base nessas estimativas, o objetivo foi identificar as estratégias operacionais mais vantajosas para o Sistema de Armazenamento de Energia em Baterias (BESS), levando em consideração tanto o fornecimento de energia solar como a demanda de consumo. Essa análise visa otimizar o uso da bateria e maximizar o retorno do investimento, proporcionando maior eficiência e redução de custos no sistema como um todo.

Tabela 2: Dados informativos bateria Magapack

Especificação	Unidade	Valor
Round Trip Efficiency	%	92

Custo total	\$	2,669,050
armazenamento máximo	MWh	3.9
Potência I/O	MW (em 2h)	1.9
calendar life	years	20
ciclo de vida	p.u	15.000
Min SOC	p.u	0.1
Max SOC	p.u	0.95
SOH(END)	p.u	0.8

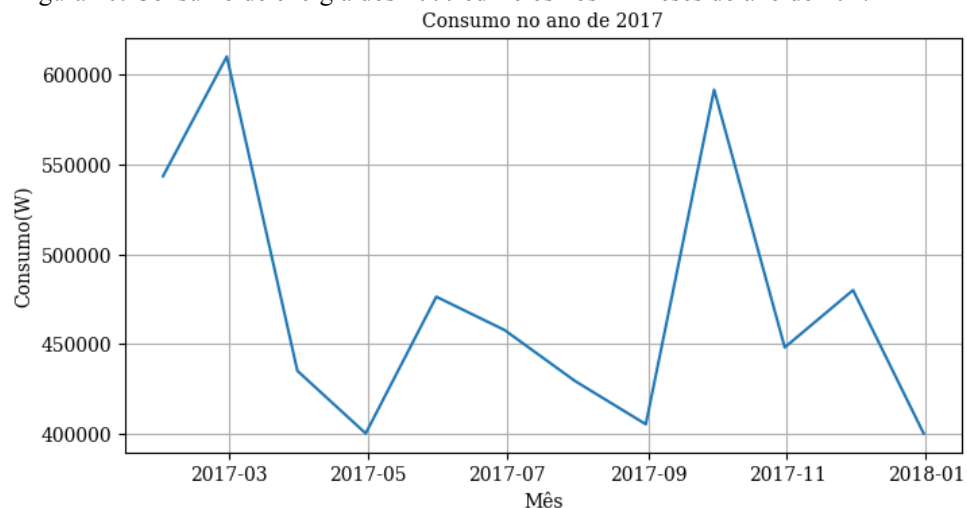
Fonte: Produção próprio autor

4.3 Carga consumida

Para a análise de consumo energéticos, um dos pontos primordiais utilizados no sistema de otimização BESS PV, foi o banco de dados disponibilizado pela SpringerNature, o mesmo utilizado por Miller, et al. (2020), que descreve um conjunto de dados abertos de 3.053 medidores de energia de 1.636 edifícios não residenciais ao longo de dois anos completos (2016 e 2017) em uma frequência horária, totalizando aproximadamente 53,6 milhões de medições (17.544 medições por medidor). Este artigo possui foco nos dados de medição de consumo referentes ao ano de 2017.

Com o objetivo de adaptar o consumo de energia para que seja útil na avaliação da eficiência de uma bateria com maior desempenho, como a Megapack, considerou-se o consumo equivalente de 1000 edifícios somados por hora. Os dados resultantes dessa adaptação podem ser visualizados na Figura 10, fornecendo insights sobre o comportamento do consumo de energia nesse período.

Figura 10: Consumo de energia dos 1000 edifícios nos 12 meses do ano de 2017



Fonte: Produção próprio autor

4.4 Modelagem Matemática Custo energético

O gerenciamento de energia baseado na maximização do autoconsumo (SCM - Self-Consumption Maximization) funciona com regras predefinidas. Em um sistema PV-Bateria, quando a geração de energia solar no local é igual ou maior que a demanda de carga, a energia PV é a primeira utilizada para fornecer às cargas locais, e a energia PV restante é usada para carregar a bateria. Se houver ainda mais energia excedente, ela será exportada para a rede de distribuição para obter retorno por meio de uma tarifa de alimentação e o excedente de energia não utilizado pode ser reduzido. Por outro lado, quando a energia solar no local não é suficiente para atender à demanda de carga, se a bateria armazenar energia suficiente, ela será descarregada para suprir as cargas. Se a potência da bateria ainda não for suficiente para atender à demanda de carga, a energia será importada da rede de distribuição. (MULLERIYAWAGE; SHEN, 2020), o fluxo pode ser observado na Figura 11.

O Mínimo Custo Anual Total do Sistema de Bateria Fotovoltaica é alcançado por meio da Otimização Operacional do BESS (MinCop), representa o conjunto das funções a ser minimizada pelo AG, leva em consideração duas variáveis principais: o C_{bat} e o C_e . O Mínimo Custo Anual de Eletricidade Quando Otimizado (C_e), é a equação que leva em conta a potência que é importada (da rede para casa) e exportada (das placas para a rede) pelo sistema Equação 7. Onde τ é o tempo em horas. A Tarifa Paga Para Utilização da Energia da Concessionária (C_{tou}), varia de acordo com o período de ponta e fora ponta, e a Tarifa de Remuneração Pela Energia Injetada na Rede (C_{fit}) é um incentivo para utilização do sistema PV .

$$C_e = \sum (P_{g2l}[\tau] \times \Delta t \times C_{tou}[\tau] - P_{pv2g}[\tau] \times \Delta t \times c_{fit}[\tau]) \quad (\text{Equação 7})$$

7)

Entretanto, o sistema brasileiro não oferece incentivos fiscais, relacionados à venda de energia excedente para as empresas fornecedoras de energia, ou seja, a pessoa possuidora do sistema não ganha retorno ao vender energia que ela produziu, assim, a tarifa de venda de energia (C_{fit}) é igual a zero, tornando a Equação 7 na Equação 8.

$$C_e = \sum (P_{g2l}[\tau] \times \Delta t \times C_{tou}[\tau]) \quad (\text{Equação 8})$$

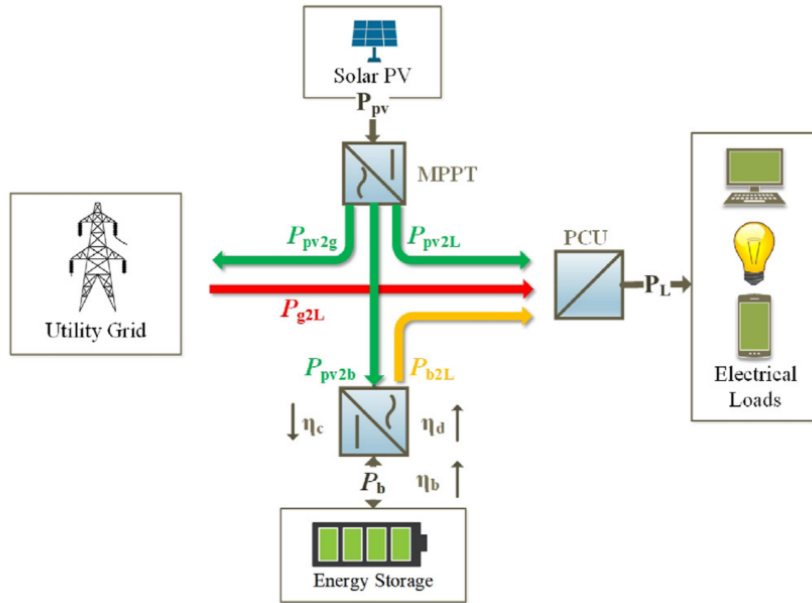
Já o Custo Anual Relacionado à Bateria (C_{bat}) Equação 9, é determinado pela degradação da bateria no final de sua vida, o custo total da bateria (C_t) e a capacidade total da bateria a ser otimizada.

$$C_{bat} = \frac{(1 - SOH[endl])}{1 - \alpha_{rep}} \times C_t \times E_b \quad (\text{Equação 9})$$

Essas duas funções, são fundamentais no contexto do MinCop Equação 10, pois permitem identificar os principais custos envolvidos na utilização da bateria fotovoltaica, bem como otimizar o consumo de energia elétrica para reduzir os gastos ao longo do tempo. Através dessa abordagem, é possível encontrar um equilíbrio entre o investimento necessário em baterias e a economia gerada pela utilização eficiente da energia solar, resultando em um sistema de energia mais sustentável e economicamente viável.

$$MinC_{op}(E_b) = C_{bat} + C_e \quad (\text{Equação 10})$$

Figura 11: Fluxo de energia entre as principais entidades em uma residência com um sistema de gerenciamento de energia baseado em SCM em um sistema de bateria fotovoltaica.



Fonte: (MULLERIYAWAGE; SHEN, 2020)

4.5 Avaliação de Retorno do investimento

Retorno de Investimento (Roi - Return on Investment) Equação 11, é a equação que retorna em porcentagem o quanto que o sistema foi bem dimensionado, ou seja, de acordo com o dimensionamento da bateria, o usuário terá um retorno ideal (não perfeito) x vezes maior que o dinheiro investido inicialmente.

$$Roi = \frac{C_{sav}}{C_{bat}} \times 100 \quad (\text{Equação 11})$$

Onde o Custo Salvo Depois da Instalação (C_{sav}) é a subtração entre: o custo anual que um usuário tem usando unicamente o sistema de geração de energia fotovoltaico e o custo anual com o sistema fotovoltaico mais a bateria, Equação 12.

$$C_{sav} = C_{pv} - C_{pv+bat} \quad (\text{Equação 12})$$

5 Resultados e Discussão

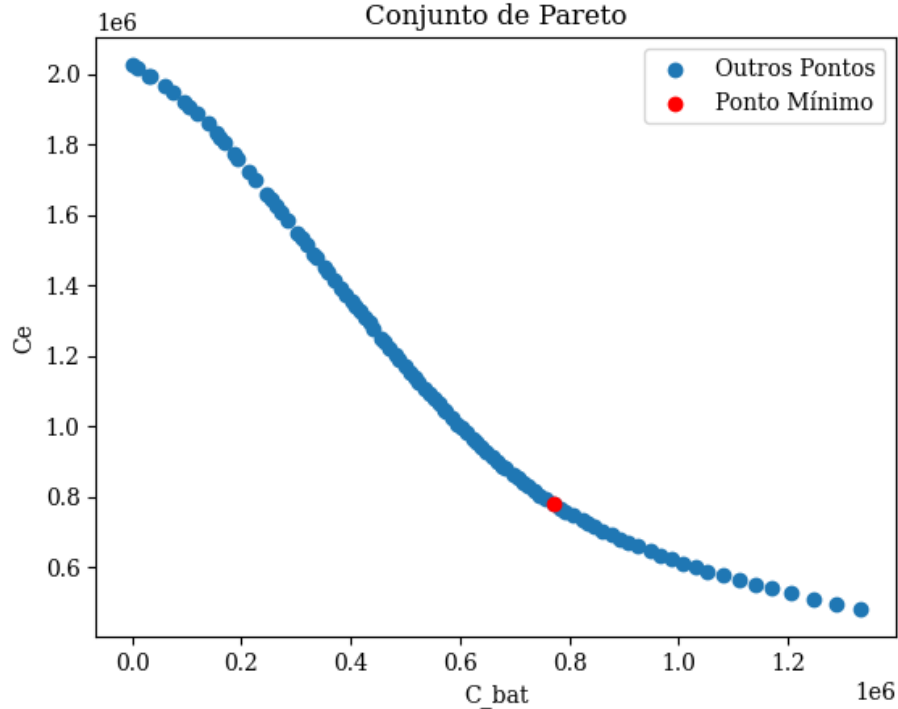
Para a obtenção dos resultados apresentados, foi empregada a biblioteca PyMOO do Python, a qual facilita a manipulação de algoritmos genéticos, permitindo a otimização personalizada do Sistema de Armazenamento de Energia em Baterias (BESS) de acordo com as necessidades de cada usuário. Para essa finalidade, utilizamos o algoritmo NSGA-III, que se mostrou eficiente na minimização das funções objetivas descritas nas Equações 8 e 9.

As referidas equações permitiram a busca do tamanho ideal do BESS, por meio da otimização dos custos anuais de eletricidade com a bateria instalada e do custo total associado à sua utilização.

O gráfico do Conjunto de Pareto, obtido por meio da otimização do Algoritmo Genético (AG), é apresentado na Figura 12. Nesse gráfico, é destacado o ponto mínimo encontrado a partir da distância euclidiana dos objetivos em relação ao ponto de origem do gráfico. Essa abordagem nos permite identificar a melhor capacidade da bateria, com o objetivo de minimizar a distância entre os custos dos objetivos.

Analisando o gráfico, é possível observar que o ponto mínimo encontra-se em uma região abaixo da chamada "Parede de Pareto", o que se deve ao fato de que o custo anual de eletricidade apresenta valores mais elevados em algumas gerações. Essa variação dos custos ao longo das gerações influencia a posição do ponto mínimo no gráfico.

Figura 12: Conjunto de Pareto comparativo de custos

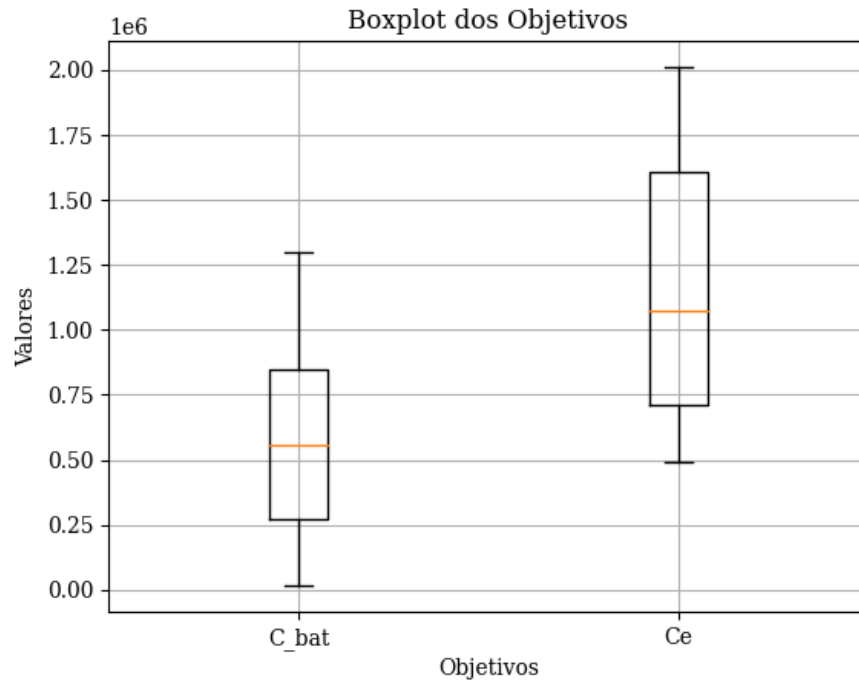


Fonte: Produção próprio autor

A distribuição dos custos pode ser visualizada no boxplot apresentado na Figura 13, onde é possível notar uma maior amplitude de valores para o custo mínimo anual de eletricidade (C_e) em comparação com o custo anual relacionado à bateria (C_{bat}). Apesar dessa maior dispersão nos valores de C_e , a posição da mediana dentro da caixa do boxplot para C_e mostra uma tendência central dos custos em direção a valores menores, indicando um objetivo de minimização do C_e .

Essa análise é relevante para compreender a variabilidade dos custos ao longo das iterações do algoritmo de otimização. A amplitude maior em C_e pode refletir uma maior diversidade de soluções possíveis para o custo mínimo anual de eletricidade, mas a presença da mediana próxima ao limite inferior da caixa sugere que o algoritmo tende a convergir para soluções com menor custo anual de eletricidade.

Figura 13: Comparação de distribuição dos custos por função objetiva




Fonte: Produção próprio autor

Na Figura 14, pode-se observar o desempenho das funções C_{bat} e C_e , representadas por pontos pares que pertencem à Ordenação Não Dominada (NDS). Cada ponto par representa uma solução encontrada durante a execução do algoritmo de otimização multiobjetivo. O objetivo é encontrar o ponto mínimo nesse gráfico, que corresponde aos melhores valores de C_{bat} e C_e . Para determinar esse ponto, utiliza-se a distância euclidiana entre cada ponto da NDS e a origem do gráfico da Fronteira de Pareto na Figura 12. A solução com a menor distância euclidiana em relação à origem é identificada como a vencedora, pois representa a combinação ótima de C_{bat} e C_e , maximizando o desempenho do sistema.

O processo de seleção do vencedor com base na distância euclidiana é crucial para garantir que a solução escolhida esteja mais próxima do ideal, considerando as restrições e objetivos do problema. Isso permite que os projetistas ou pesquisadores identifiquem e implementem uma solução que equilibre efetivamente os valores de C_{bat} e C_e , obtendo um resultado ótimo para o sistema em questão. Ao adotar essa abordagem, pode-se alcançar uma melhor eficiência energética, economia de recursos e desempenho geral do sistema, proporcionando benefícios significativos em aplicações práticas.

Figura 14: Avaliação da evolução dos objetivos durante cada geração



Fonte: Produção próprio autor

6 Conclusões

Com base nos dados adquiridos, foi possível calcular a capacidade da bateria, que totaliza em 2.259.114 W, considerando a suposição de 1000 casas com o mesmo consumo energético durante um ano. O retorno sobre o investimento (ROI) para o sistema de bateria é de 61,74%, indicando um potencial ganho financeiro promissor.

O C_{pv} representa o custo anual que um usuário tem ao utilizar exclusivamente o sistema de geração de energia fotovoltaico, com um valor de 2.026.548 \$. Por sua vez, o C_{op} , que é o Mínimo Custo Anual Total do Sistema de Bateria Fotovoltaica, alcançou um valor menor, totalizando 1.549.301 \$, por meio da Otimização Operacional do BESS.

Esses números ressaltam a viabilidade econômica e a eficiência de integrar uma solução de armazenamento de bateria ao sistema de energia solar. Considerando a considerável capacidade da bateria e o retorno favorável do investimento, a implementação desse sistema se apresenta como uma solução atrativa tanto para ambientes residenciais quanto comerciais.

Em conclusão, os dados demonstram que investir em um sistema de energia solar com um Sistema de Armazenamento de Energia em Bateria otimizado é uma escolha financeiramente viável e sustentável em termos ambientais. A combinação de geração de energia renovável com uma capacidade eficiente de armazenamento não só garante independência energética, mas também abre caminho para um futuro mais verde, proporcionando vantagens de economia de custos a longo prazo.

Referências Bibliográficas

Costa, F. R. B.; Alves, J. R. M.. Implementação de algoritmo NSGA-III com operador de estimativa de distribuição. XIII Encontro Anual de Computação. 2017.

DE LACERDA, Estéfane GM; DE CARVALHO, ACPLF. Introdução aos algoritmos genéticos. **Sistemas inteligentes: aplicações a recursos hídricos e ciências ambientais**, v. 1, p. 99-148, 1999.

EL-BIDAIRI, Kutaiba S. et al. Optimal sizing of Battery Energy Storage Systems for dynamic frequency control in an islanded microgrid: A case study of Flinders Island, Australia. **Energy**, v. 195, p. 117059, 2020.

MAHMOUD, Thair Shakir; AHMED, Bestoun S.; HASSAN, Mohammed Y. The role of intelligent generation control algorithms in optimizing battery energy storage systems size in microgrids: A case study from Western Australia. **Energy Conversion and Management**, v. 196, p. 1335-1352, 2019.

Massago, Sadao. Introdução ao Algoritmo Genético. 2013

Miller, C., Kathirgamanathan, A., Picchetti, B. et al. The Building Data Genome Project 2, energy meter data from the ASHRAE Great Energy Predictor III competition. *Sci Data* 7, 368 (2020).
<https://doi.org/10.1038/s41597-020-00712-x>

MULLERIYAWAGE, U. G. K.; SHEN, W. X. Optimally sizing of battery energy storage capacity by operational optimization of residential PV-Battery systems: An Australian household case study. **Renewable Energy**, v. 160, p. 852-864, 2020.

NEVES, João Gabriel Lima. Estudo empírico sobre performance do módulo NSGA-III na ferramenta DCT. 2021.

PACHECO, Marco Aurélio Cavalcanti et al. Algoritmos genéticos: princípios e aplicações. **ICA: Laboratório de Inteligência Computacional Aplicada. Departamento de Engenharia Elétrica. Pontifícia Universidade Católica do Rio de Janeiro. Fonte desconhecida**, v. 28, 1999.

YANG, Renata Lautert et al. Estimação da temperatura em células fotovoltaicas para sistemas fotovoltaicos conectados à rede elétrica em Curitiba. In: **SmartEnergy Paraná Conf., Curitiba**. 2018.