

Otimização do Sistema de Armazenamento de Energia em Bateria

Arthur Coelho Estevão¹

¹Programa de Pós-Graduação em Engenharia Elétrica (PPGEE),
Centro Tecnológico (CT) – Universidade Federal do Espírito Santo (UFES)

arthur.estevao@edu.ufes.br

Abstract. *The optimization of Battery Energy Storage Systems (BESS) is essential for the integration of renewable sources in zero net energy buildings (ZNEB) and for improving the efficiency of the power system. This work applies evolutionary algorithms (NSGA-III) for BESS sizing, considering economic objectives (minimization of annual electricity cost and annual battery-related cost) and operational effects such as photovoltaic panel soiling. Hourly series of synthetic generation (PV model) and consumption (Building Data Genome Project 2) were used for the region of Vitória-ES (2016–2017). The simulation and optimization code was implemented in Python (PyMOO, pvlb) and is available in the appendix.*

Resumo. *A otimização do Sistema de Armazenamento de Energia em Bateria (BESS) é fundamental para a integração de fontes renováveis em edificações com consumo líquido de energia zero (ZNEB) e aprimoramento da eficiência do sistema elétrico. Este trabalho aplica algoritmos evolutivos (NSGA-III) para dimensionamento do BESS, considerando objetivos econômicos (minimização do custo anual de eletricidade e do custo anual relacionado à bateria) e efeitos operacionais como sujidade nos painéis fotovoltaicos. Foram usadas séries horárias de geração sintética (modelo PV) e consumo (Building Data Genome Project 2) para a região de Vitória-ES (2016–2017). O código de simulação e otimização foi implementado em Python (PyMOO, pvlb) e está disponível no apêndice.*

1. Introdução

O BESS é uma solução comprovada que desempenha um papel fundamental na integração bem-sucedida de fontes de energia renovável nos sistemas elétricos. Sua capacidade de suavizar a potência de saída das fontes renováveis, como energia solar e eólica, é crucial para lidar com a variabilidade inerente dessas fontes e garantir um fornecimento de energia estável e confiável [Mahmoud et al. 2019]. Além disso, [Mahmoud et al. 2019] destaca que o BESS também desempenha um papel crucial na estabilização dos microgrids. À medida que a adoção de microgrids cresce, especialmente em comunidades isoladas ou áreas remotas, a presença de sistemas de armazenamento de energia se torna ainda mais vital para garantir o equilíbrio entre a oferta e a demanda de energia. A capacidade de armazenar o excesso de energia produzida durante os períodos de maior geração e liberá-lo quando a demanda é maior permite uma operação mais eficiente e autônoma das microrredes.

Além dos benefícios operacionais, o BESS também oferece vantagens econômicas ao sistema elétrico. Ao otimizar a utilização de fontes renováveis e evitar a necessidade de construção de infraestruturas adicionais para lidar com picos de demanda, o custo geral do sistema elétrico pode ser reduzido significativamente. Nesse contexto, embora o armazenamento represente uma solução central para a integração de renováveis, é igualmente necessário considerar fatores externos que impactam diretamente a eficiência da geração, em especial nos sistemas fotovoltaicos.

Um dos fatores relevantes que afetam diretamente a eficiência dos sistemas fotovoltaicos é a sujidade (*soiling*), que consiste no acúmulo de poeira, partículas e poluentes sobre os módulos solares. Esse fenômeno reduz a irradiância efetiva que atinge as células e, conseqüentemente, a produção de energia.

[Kimber et al. 2006] propuseram um modelo empírico amplamente utilizado para estimar perdas de geração devido à sujidade. Estudos como os de [Ilse et al. 2019] e [Sarver et al. 2013] mostram que a magnitude do impacto da sujidade pode variar entre 3% e 4%, dependendo das condições climáticas locais, da taxa de deposição de partículas e da frequência de chuvas. Em regiões urbanas com altos índices de poluição, esses efeitos são ainda mais severos. Além disso, [Mani and Pillai 2010] revisaram diversos trabalhos mostrando que a falta de limpeza adequada pode comprometer significativamente a viabilidade econômica de sistemas fotovoltaicos de larga escala.

Portanto, o estudo da sujidade e sua modelagem se tornam essenciais para dimensionar corretamente os sistemas de geração e armazenamento, garantindo previsões mais realistas de geração e maior confiabilidade nos cálculos de retorno sobre o investimento.

2. Conceitualização e Revisão Bibliográfica

2.1. Virtual Power Plants (VPP)

Segundo [Saboori et al. 2011], a geração de energia distribuída pode ser melhor compreendida e integrada por meio do conceito de *Virtual Power Plants* (VPP), composta pela integração de diversas unidades geradoras distribuídas, formando uma “única unidade virtual geradora”. Essa abordagem possibilita o gerenciamento individualizado de cada unidade e, ao mesmo tempo, funcione de forma integrada, otimizando os prosumidores conectados à rede.

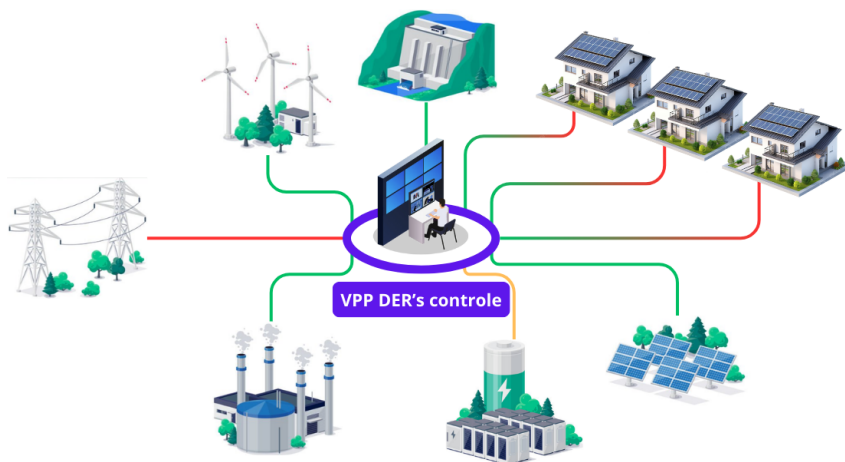


Figura 1. Arquitetura básica de uma VPP

A Figura 1 representa uma VPP, e demonstra como os DERs individuais podem acessar todo o mercado de energia, integrando geradores, consumidores, prosumidores e sistemas de armazenamento. Essa integração permite a troca direta de energia entre os membros, sem a necessidade da intervenção da concessionária cativa. Na Figura, as linhas verdes representam a geração de energia da rede, a amarela indica o sistema de armazenamento e a vermelha, os consumidores e o sistema de energia das concessionárias locais, contudo os usuários podem adquirir energia tanto da rede cativa quanto da rede VPP.

Nesse contexto, os DERs abrangem parques eólicos, solares, termelétricas e consumidores residenciais ou industriais. A operação integrada do sistema promove o uso otimizado da capacidade disponível, resultando em maior eficiência operacional. Adicionalmente, a própria VPP pode funcionar como um centro de armazenamento por meio de BESS, vendendo energia para as concessionárias locais em períodos de alta tarifa e adquirindo energia quando as tarifas estão mais baixas.

2.2. Algoritmos Evolucionários NSGA-III

Métodos de otimização evolucionária multi/muitos objetivos *Evolutionary multi/many objective optimization* (EMO) surgiram no início dos anos noventa e desde então é crescente a quantidade de pesquisadores nessa área.

Impulsionado cada vez mais pela evolução dos computadores, sua popularização também aconteceu na área industrial com o aparecimento de softwares EMO comerciais. No cotidiano os métodos EMO tem demonstrado cada vez mais capacidade para resolver problemas com muitos objetivos. Os métodos de otimização multi/muitos objetivos têm basicamente dois conceitos principais: diminuir a distância entre a frente não dominada e a frente pareto-ótimo e encontrar um conjunto de soluções diversificadas.[Costa and Alves 2017]

Non-Dominated Sorting Genetic Algorithm (NSGA-III) é um algoritmo genético, evolução do NSGA-II, que busca encontrar a clusterização adequada a sistemas, usando um paradigma de otimização chamado many-objetivo, derivado do paradigma multi-objetivo.[Neves 2021]




Figura 2. Fluxo de funcionamento do NSGA-III

O propósito dela é tentar diminuir a complexidade computacional pela técnica de classificação por não-dominância, que faz o elitismo com base em frentes de soluções ditas não-dominadas. O algoritmo Figura 2 trabalha com uma população filha, criada a partir de uma população pai inicial, utiliza um operador de seleção/cruzamento/mutação(AG) e mantém sua diversidade por meio de um mecanismo de preservação de nichos que busca soluções próximas da projeção criada por pontos de referência.[Costa and Alves 2017]

2.3. Gráfico de frente de Pareto

O gráfico de frente de Pareto, também conhecido como gráfico de dispersão da frente de Pareto, é uma ferramenta essencial na análise de problemas de otimização multiobjetivo. Ele representa visualmente as soluções não dominadas encontradas durante a busca por soluções ótimas em um problema com múltiplos objetivos.

Em problemas multiobjetivos, geralmente não existe uma única solução que seja a melhor em todos os objetivos simultaneamente. Em vez disso, há várias soluções que representam diferentes compromissos entre os objetivos. Essas soluções não podem ser melhoradas em um objetivo sem piorar em outro, e são chamadas de soluções não dominadas ou soluções de Pareto.

O gráfico de frente de Pareto mostra essas soluções não dominadas em um espaço de objetivos, Figura 3. Cada ponto no gráfico representa uma solução do problema, onde os eixos são os diferentes objetivos. As soluções não dominadas formam uma curva ou superfície chamada de "frente de Pareto", que representa todas as possíveis soluções ótimas.




Figura 3. Gráfico de dispersão de frente de Pareto

3. Implementação

A metodologia de simulação abrange a modelagem do consumo energético, a simulação de geração fotovoltaica e a inclusão de um modelo de degradação por sujeidade, o que confere um alto grau de realismo à análise.

Este trabalho propõe um sistema de simulação de prosumidores em uma rede *blockchain*, visando a otimização da conta de energia elétrica por meio da negociação automatizada de créditos energéticos. O sistema utiliza contratos inteligentes e *tokens*

para representar os créditos como ativos financeiros (em R\$), possibilitando sua compra e venda conforme condições pré-estabelecidas.

A implementação foca em consumidores monômios de baixa tensão e busca, através dos contratos inteligentes, oferecer uma **Tarifa de Energia (TE)** inferior à praticada pela concessionária regional. A análise considera duas modalidades tarifárias: convencional e branca. A TE aplicada é baseada na Resolução 1000 da ANEEL [?], desconsiderando a Tarifa de Utilização do Sistema de Distribuição (TUSD).

3.1. Modelagem Tarifas de Energia

Para a análise econômica do sistema, os usuários foram considerados como consumidores de alta tensão, enquadrados na modalidade tarifária verde do Grupo A. Nessa modalidade, o valor da tarifa varia de acordo com o período do dia em que o consumo ocorre, diferenciando-se em "ponta" e "fora de ponta". Essa estrutura tarifária busca refletir o custo real de fornecimento de energia em função da demanda horária. A Figura 4 mostra a evolução da tarifa de uso da rede (TUSD+TE) ao longo dos anos de 2016 e 2017.



Figura 4. Tarifas nos anos de 2016 à 2017

O Faturamento da Energia Elétrica Ativa (FEA) por posto tarifário i , expresso em Reais (R\$), é determinado pela seguinte equação :

$$FEA = \sum_i EEAM(i) \cdot (TE(i) + TUSD(i)) \quad (1)$$

onde $EEAM(i)$ representa o montante de **Energia Elétrica Ativa Medida** em megawatt-hora (MWh) para cada posto tarifário i , e $TE(i)$ e $TUSD(i)$ correspondem à Tarifa de Energia e à Tarifa de Utilização do Sistema de Distribuição aplicáveis ao respectivo posto. As tarifas específicas utilizadas foram baseadas nas seguintes resoluções homologatórias da ANEEL: RESOLUÇÃO HOMOLOGATÓRIA Nº 1.927, DE 4 DE AGOSTO DE 2015; RESOLUÇÃO HOMOLOGATÓRIA Nº 2.182, DE 29 DE NOVEMBRO DE 2016; e RESOLUÇÃO HOMOLOGATÓRIA Nº 2.207, DE 14 DE MARÇO DE 2017.

O posto tarifário "ponta" possui a maior tarifa, correspondendo aos períodos de

maior demanda, geralmente entre 18h e 21h. Já o posto "fora de ponta" apresenta a tarifa mais baixa, correspondendo aos períodos de menor demanda por energia elétrica.

3.2. Modelagem do Consumo Energético

Para a análise de consumo, um dos pontos primordiais utilizados no sistema foi o *dataset* disponibilizado pela *SpringerNature* [Team 2020] e utilizado por [Miller et al. 2020]. Esse *dataset* descreve um conjunto de dados abertos provenientes de 3.053 medidores de energia, instalados em 1.636 edifícios não residenciais, ao longo de dois anos completos (2016 e 2017), com registros em frequência horária, totalizando aproximadamente 53,6 milhões de medições (17.544 medições por medidor). Para esta análise, foram selecionados aleatoriamente 100 edifícios, que foram tratados como prosumidores a partir da adição de uma carga de injeção simulada, representando a geração própria de energia. Dentre esses, a Figura 5 apresenta o consumo mensal correspondente para 10 usuários selecionados como exemplo. Dos dez usuários analisados, Isaiah e Reyna possuem registros apenas para o segundo ano, sem justificativa aparente para essa ausência de dados no primeiro ano.




Figura 5. Consumo de energia por usuário no *dataset* utilizado

3.3. Sistemas Fotovoltaico (PV)

Foi utilizado um algoritmo para simular dados de geração solar, uma vez que não havia disponibilidade de informações reais de um sistema fotovoltaico instalado. A simulação foi realizada com base em dados meteorológicos da região de Vitória referentes aos anos de 2016 e 2017 [INMET 2025]. O objetivo foi fornecer uma estimativa da geração de energia caso um sistema de placas fotovoltaicas fosse instalado na região. Nessa simulação, foi utilizado como referência o módulo fotovoltaico ODA280-30-P, Tabela 1, determinando a quantidade necessária de placas N_p para cada edifício com base no consumo médio horário, conforme expressa a Equação 2:

$$N_p = \frac{c_m}{p \cdot I_r \cdot h_e \cdot ap} \quad (2)$$

onde c_m é o consumo médio, horário, p é a potência nominal do módulo, ap é o fator de aproveitamento (0.75, considerando uma perda de 25%), I_r é a irradiação solar média (4,5 Wh/m²), e h_e é o tempo de exposição ao sol (6h).

Para calcular os valores de potência ao longo do período, é necessário determinar a temperatura dos painéis solares. Para isso, foi utilizada a equação proposta por

Tabela 1. Especificações do Módulo Fotovoltaico ODA280-30-P

Especificação	Unidade	Valor
Imppt	corrente no ponto de máxima potência (A)	8,77
Vmppt	tensão no ponto de máxima potência (V)	31,94
Not	temperatura nominal de operação da célula (°C)	45
Isc	corrente de curto circuito da célula (A)	9,41
Voc	tensão de circuito aberto do módulo (V)	38,33
K_i	coeficiente de corrente/temperatura (A/°C)	0,06
K_v	coeficiente de tensão/temperatura (V/°C)	-0,3
R_{NOCT}	irradiância total (W/m ²)	1000
τ_a	produto da transmitância-absortância (p.u)	0,9
η_c	eficiência de conversão do módulo (%)	18,99

[Yang et al. 2018], conforme descrito na Equação 3 em que V_v representa a velocidade do vento, em m/s, I_r a irradiação, em m/s e demais dados provenientes da Tabela 1. Os dados de irradiância solar, temperatura ambiente e velocidade do vento foram obtidos no portal do [INMET 2025] para a estação A612, localizada na região de Vitória.

$$T_c = T_a + \left[\frac{I_r}{R_{NOCT}} \cdot \left(\frac{9,5}{5,7 + 3,8 \cdot V_v} \right) \cdot (Not - 20) \cdot \left(1 - \frac{\eta_c}{\tau_a} \right) \right] \quad (3)$$

Com a temperatura dos painéis (T_c) determinada, as Equações 4 e 5 são utilizadas para calcular a corrente elétrica e a tensão no ponto de medição. Esses cálculos dependem exclusivamente dos valores de corrente de curto-circuito (I_{sc}), tensão de circuito aberto (V_{oc}), coeficientes de temperatura de corrente (K_i) e tensão (K_v).

$$I = I_r \cdot (I_{sc} + K_i \cdot (T_c - 25)) \quad (4)$$

$$V = V_{oc} - K_v \cdot (T_c - 25) \quad (5)$$

$$FF = \frac{V_{mppt} \cdot I_{mppt}}{V_{oc} \cdot I_{sc}} \quad (6)$$

Já o Fator de Forma (FF), dado pela Equação 6, é uma medida para avaliar a eficiência dos painéis fotovoltaicos e é calculado com base em parâmetros fundamentais, como a tensão máxima de potência (V_{mppt}), corrente máxima de potência (I_{mppt}), tensão de circuito aberto (V_{oc}) e corrente de curto-circuito (I_{sc}).

$$Pot_{PVM} = N_{Paineis} * FF * V * I \quad (7)$$

Com base nas equações apresentadas, podemos formular a expressão que descreve a potência do sistema fotovoltaico (Pot_{PVM}) em cada instante de tempo por meio da Equação 7. Essa equação fornece as informações essenciais para a criação de um *dataframe* com os dados de geração no período completo dos anos de 2016 e 2017. Como exemplo, as gerações do dia 1º de janeiro de 2016 podem ser visualizadas na Figura 6.

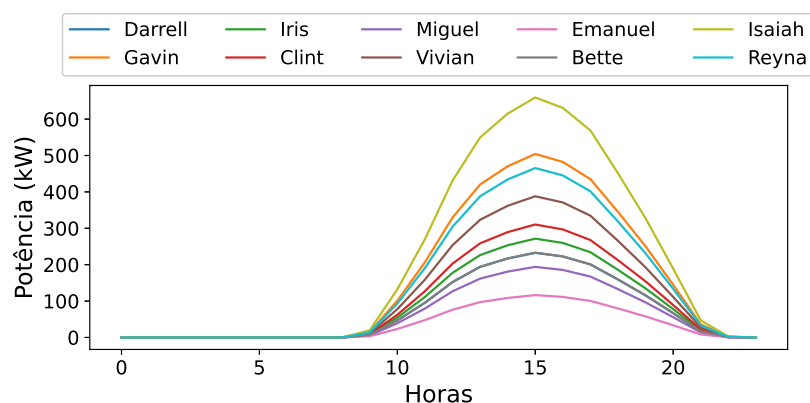


Figura 6. Geração fotovoltaica em 1º de janeiro de 2016

3.4. Modelagem de Sujidade (*Soiling*)

Para adicionar realismo à simulação, foi aplicado um modelo de sujidade, o modelo de Kimber, que quantifica a perda de eficiência dos painéis devido ao acúmulo de poeira e sujeira. Este modelo considera uma taxa de perda diária de 0.2% e uma perda máxima de 30%. A sujeira é eliminada quando a precipitação atinge um limite de 25 mm, após o qual há um período de carência de 14 dias sem acúmulo. Os dados meteorológicos de precipitação utilizados também foram obtidos por meio do portal do [INMET 2025]. O acúmulo de sujidade ao longo do tempo é ilustrado na Figura 7.




Figura 7. Acúmulo de sujidade ao longo dos anos

A aplicação deste modelo teve um impacto mensurável na geração de energia, resultando em uma perda de potência de 8193.90 MW ao longo dos dois anos de simulação, o que corresponde a uma perda de 3.69% da potência total gerada. A diferença entre a geração de energia acumulada com e sem a aplicação do modelo de sujidade para os 100 usuários é explicitada na Figura 8. A inclusão deste fator não apenas aumenta a precisão do estudo, mas também influencia diretamente a análise econômica. Adicionalmente, a modelagem de sujidade serve para verificar o impacto da perda de eficiência no retorno sobre o investimento (ROI) das baterias. A perda de geração devido à sujidade aumenta a dependência do sistema em relação à energia da rede ou, alternativamente, do BESS, tornando o dimensionamento e a otimização do sistema de armazenamento ainda mais críticos para garantir a viabilidade financeira do projeto.




Figura 8. Comparativo da geração acumulada com e sem sujidade para 100 usuários

3.5. Análise Econômica e Otimização

O gerenciamento de energia baseado na maximização do autoconsumo (SCM - *Self-Consumption Maximization*) funciona com regras predefinidas. Em um sistema PV-Bateria, quando a geração de energia solar no local é igual ou maior que a demanda de carga, a energia PV é a primeira utilizada para fornecer às cargas locais, e a energia PV restante é usada para carregar a bateria. Se houver ainda mais energia excedente, ela será exportada para a rede de distribuição para obter retorno por meio de uma tarifa de alimentação e o excedente de energia não utilizado pode ser reduzido. Por outro lado, quando a energia solar no local não é suficiente para atender à demanda de carga, se a bateria armazenar energia suficiente, ela será descarregada para suprir as cargas. Se a potência da bateria ainda não for suficiente para atender à demanda de carga, a energia será importada da rede de distribuição. [Mulleriyawage and Shen 2020], o fluxo pode ser observado na Figura 9.

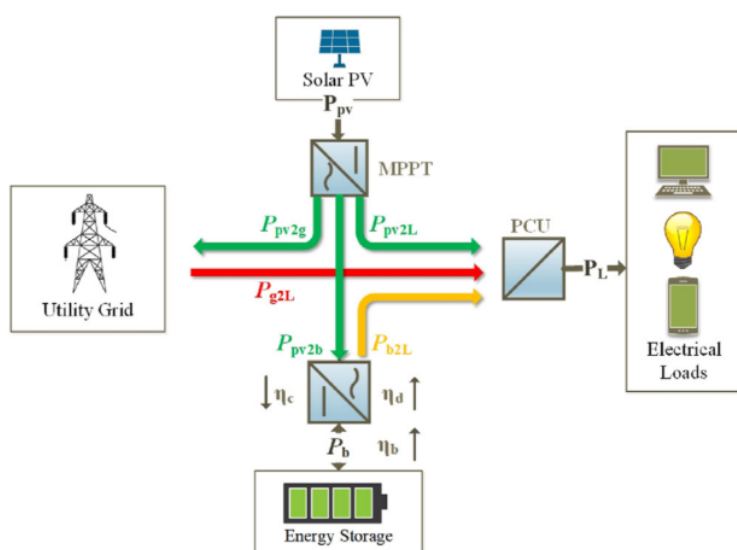


Figura 9. Fluxo de energia entre as principais entidades em uma residência com um sistema de gerenciamento de energia baseado em SCM em um BESS.

O estudo econômico foi realizado com base na otimização do BESS, buscando o equilíbrio entre custos e benefícios por meio da minimização de múltiplos objetivos, um desafio ideal para o algoritmo genético NSGA-III. As funções de custo a serem minimizadas pelo algoritmo são o custo anual de eletricidade C_e e o custo da bateria C_{bat} .

- **Custo Anual de Eletricidade (C_e):** Representa o custo total da energia importada da rede da concessionária. A Equação 8 define essa função, onde $P_{g2l}(\tau)$ é a potência importada da rede no instante de tempo τ , e $C_{tou}(\tau)$ é a tarifa de uso da rede, que corresponde à soma da Tarifa de Energia (TE) e a Tarifa de Utilização do Sistema de Distribuição (TUSD) no instante.

$$C_e = \Sigma(P_{g2l}[\tau] \cdot \Delta t \cdot C_{tou}[\tau]) \quad (8)$$

- **Custo Anual Relacionado à Bateria (C_{bat}):** Reflete o custo da bateria ao longo de sua vida útil. A Equação 9 considera o estado de saúde final da bateria ($SOH[end]$), a capacidade total da bateria (E_b) e seu custo total (C_t), entre outros parâmetros.

$$C_{bat} = \frac{(1 - SOH[end])}{(1 - \alpha_{rep})} \cdot C_t \cdot E_b \quad (9)$$

- **Custo Operacional Mínimo ($MinC_{op}$):** A principal função objetivo a ser minimizada, representando a soma do custo anual da bateria e do custo anual da eletricidade, conforme a Equação 10.

$$MinC_{op}(E_b) = C_{bat} + C_e \quad (10)$$

- **Custo Salvo (C_{sav}):** Representa a economia anual obtida com o sistema otimizado em comparação a um sistema de geração fotovoltaica sem bateria, conforme a Equação 11. Essa economia é calculada subtraindo o custo anual do sistema fotovoltaico com bateria (C_{pv+bat}) do custo anual de um sistema que utiliza apenas a geração fotovoltaica (C_{pv}).

$$C_{sav} = C_{pv} - C_{pv+bat} \quad (11)$$

- **Retorno de Investimento (ROI):** O principal indicador de desempenho, expresso em porcentagem, que mede a rentabilidade do investimento na bateria, conforme a Equação 12.

$$ROI = \frac{C_{sav}}{C_{bat}} \times 100 \quad (12)$$

4. Avaliação e Resultados

Os resultados da otimização com o NSGA-III produziram uma série de soluções ideais. A Frente de Pareto, obtida por meio da otimização do Algoritmo Genético (AG), é ilustrada na Figura 10, que compara os resultados sem e com o modelo de sujidade. Em ambos os gráficos, o ponto mínimo é destacado, representando a melhor combinação de custos anuais de eletricidade e da bateria, identificada a partir da menor distância euclidiana em relação à origem.

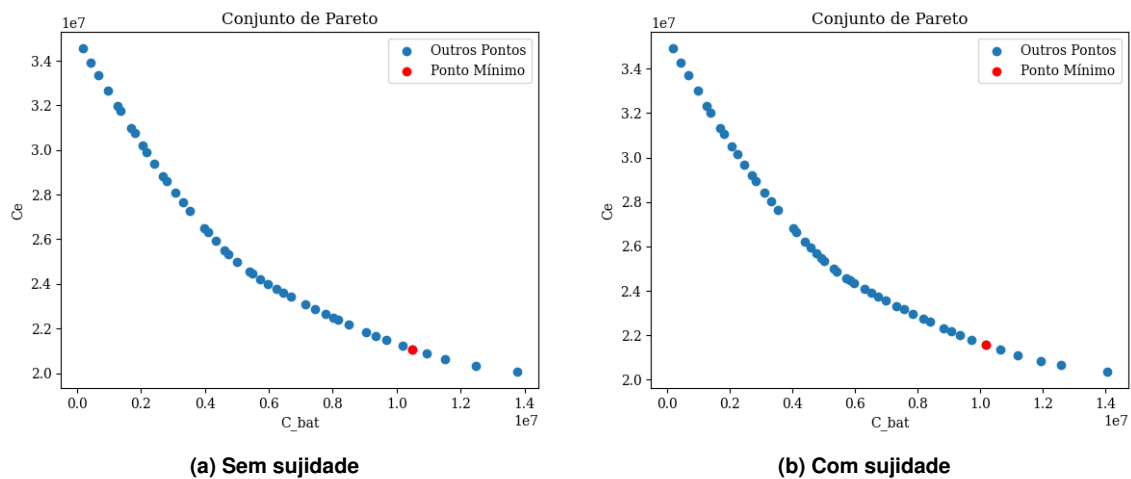


Figura 10. Conjunto de Pareto considerando (a) ausência e (b) presença de sujidade

A distribuição dos custos anuais pode ser visualizada nos boxplots apresentados na Figura 11, que comparam as distribuições de custo com e sem sujidade. Observa-se que, em ambos os casos, o custo anual de eletricidade (C_e) é substancialmente maior que o custo associado à bateria (C_{bat}), o que evidencia que o impacto econômico mais significativo da operação da VPP está relacionado à compra de energia da rede. Além disso, a amplitude interquartil de C_e é mais elevada, indicando maior variabilidade das soluções encontradas pelo algoritmo nesse objetivo, enquanto C_{bat} apresenta valores mais concentrados e tendência de minimização, dado que a mediana encontra-se próxima ao limite inferior da caixa do boxplot.





Figura 11. Boxplots dos objetivos considerando (a) ausência e (b) presença de sujidade

De forma complementar, a análise dos boxplots da Figura 11 está em consonância com a Frente de Pareto da Figura 10, uma vez que a maior dispersão observada em C_e reflete a diversidade de soluções encontradas para este objetivo, enquanto C_{bat} apresenta soluções mais concentradas, indicando menor variação no impacto econômico associado


às baterias. Isso demonstra que a estratégia de otimização consegue explorar diferentes alternativas de custo de eletricidade, ao mesmo tempo em que mantém um controle mais restrito sobre os custos de armazenamento.

A análise detalhada das soluções mostra que a configuração ótima, definida pela menor distância euclidiana em relação à origem, corresponde a uma capacidade de bateria de 18.47 MWh. Essa solução resulta em um custo de bateria (C_{bat}) de R\$ 10.180.315,33. Os valores consolidados de custo total da VPP indicam que, sem considerar a sujidade, obteve-se $C_{pv} = \text{R\$ } 34.985.865,60$ e $C_{op} = \text{R\$ } 30.486.880,88$, resultando em um ROI de 71,47%. Com a inclusão da sujidade, os resultados foram $C_{pv} = \text{R\$ } 35.323.091,55$ e $C_{op} = \text{R\$ } 30.141.778,59$, com ROI de 71,35%. A diferença de apenas 0,12 pontos percentuais evidencia que, embora a sujeira seja um fator relevante, a otimização dos dias de lavagem dos módulos pode não resultar em um aumento percentual considerável no ROI.

Adicionalmente, foi executada uma versão estendida do algoritmo, na qual se incluiu como terceiro objetivo a determinação dos *melhores dias de lavagem dos painéis*. Esse modelo considerou simultaneamente C_{bat} , C_e e os dias de lavagem como variáveis de otimização. Os resultados, ilustrados na Figura 12, mostram a comparação entre os cenários de sujidade sem limpeza e com a otimização dos dias de lavagem. Nessa configuração, obteve-se $C_{pv} = \text{R\$ } 35.451.534,71$ e $C_{op} = \text{R\$ } 30.616.492,58$, com ROI de 71,33%. Esse resultado é particularmente relevante: apesar da lavagem reduzir parcialmente os efeitos da sujidade, o custo adicional da operação resultou em um ROI inferior ao observado nos dois cenários anteriores. Assim, conclui-se que, sob as premissas deste estudo, a lavagem periódica dos painéis ***não se justifica economicamente***, já que o custo da manutenção é maior do que a perda associada à sujidade.



(a) Distribuição da sujidade sem lavagem



(b) Distribuição da sujidade com otimização dos dias de lavagem

Figura 12. Evolução da sujidade ao longo do tempo considerando (a) ausência e (b) presença da otimização de lavagem

5. Conclusão

Este trabalho apresentou a aplicação do NSGA-III para a otimização de sistemas de armazenamento de energia em uma Usina Virtual de Potência (VPP), considerando cenários com e sem o impacto da sujidade nos módulos fotovoltaicos. Os resultados demonstraram a eficácia do método de otimização multiobjetivo na identificação de soluções que equilibram os custos anuais de eletricidade e de bateria, fornecendo subsídios sólidos para a tomada de decisão em projetos energéticos.

A análise detalhada indicou que uma capacidade de bateria de 18,47 MWh proporciona um ROI entre 71,35% e 71,47%, dependendo da consideração da sujidade. Ao incluir a otimização dos dias de lavagem dos painéis, o ROI apresentou leve redução para 71,33%. Isso evidencia que, nas condições simuladas, o custo da lavagem periódica supera a perda econômica associada à sujidade, tornando a limpeza regular economicamente desvantajosa. Dessa forma, a mitigação dos efeitos da sujidade é mais eficientemente alcançada por meio da própria otimização do BESS.

Para trabalhos futuros, recomenda-se ampliar a pesquisa incorporando novos objetivos de otimização, como a modelagem da degradação do BESS ao longo de sua vida útil, permitindo uma análise econômica mais realista. Além disso, a integração de mecanismos de precificação dinâmica na VPP, capazes de responder em tempo real às variações de oferta e demanda, pode elevar a eficiência do sistema. Por fim, a implementação de

um projeto-piloto em ambiente real é fundamental para validar os resultados obtidos em simulação e explorar os desafios e oportunidades de escalabilidade do sistema proposto.

Referências

- Costa, F. R. B. and Alves, J. R. M. (2017). Implementação de algoritmo nsga-iii com operador de estimativa de distribuição. In *XIII Encontro Anual de Computação (EnAComp 2017)*, page —. Universidade Federal de Goiás. Anais disponíveis em EnAComp 2017, maio de 2017.
- Ilse, K., Micheli, L., Figgis, B. W., Lange, K., Daßler, D., Hanifi, H., Wolfertstetter, F., Naumann, V., Hagendorf, C., Gottschalg, R., et al. (2019). Techno-economic assessment of soiling losses and mitigation strategies for solar power generation. *Joule*, 3(10):2303–2321.
- INMET (2025). Tabela de dados das estações - vitoria a612. Instituto Nacional de Meteorologia, Disponível em <https://tempo.inmet.gov.br/TabelaEstacoes/A612>. Acessado em: 19 Janeiro 2025.
- Kimber, A., Mitchell, L., Nogradi, S., and Wenger, H. (2006). The effect of soiling on large grid-connected photovoltaic systems in california and the southwest region of the united states. 2:2391–2395.
- Mahmoud, T. S., Ahmed, B. S., and Hassan, M. Y. (2019). The role of intelligent generation control algorithms in optimizing battery energy storage systems size in microgrids: A case study from western australia. *Energy Conversion and Management*, 196:1335–1352.
- Mani, M. and Pillai, R. (2010). Impact of dust on solar photovoltaic (pv) performance: Research status, challenges and recommendations. *Renewable and sustainable energy reviews*, 14(9):3124–3131.
- Miller, C. et al. (2020). The building data genome project 2, energy meter data from the ashrae great energy predictor iii competition. *Scientific data*, 7(1):368.
- Mulleriyawage, U. and Shen, W. (2020). Optimally sizing of battery energy storage capacity by operational optimization of residential pv-battery systems: An australian household case study. *Renewable Energy*, 160:852–864.
- Neves, J. G. L. (2021). Estudo empírico sobre performance do módulo nsga-iii na ferramenta dct. Data de publicação: 27-Jun-2022.
- Saboori, H., Mohammadi, M., and Taghe, R. (2011). Virtual power plant (vpp), definition, concept, components and types. In *2011 Asia-Pacific power and energy engineering conference*, pages 1–4. IEEE.
- Sarver, T., Al-Qaraghuli, A., and Kazmerski, L. L. (2013). A comprehensive review of the impact of dust on the use of solar energy: History, investigations, results, literature, and mitigation approaches. *Renewable and sustainable energy Reviews*, 22:698–733.
- Team, S. D. C. (2020). Metadata record for: The building data genome project 2, energy meter data from the ashrae great energy predictor iii competition. Dataset.

Yang, R. L. et al. (2018). Estimação da temperatura em células fotovoltaicas para sistemas fotovoltaicos conectados à rede elétrica em Curitiba. In *Conferência Internacional de Energias Inteligentes-Smart Energy CIEI&EXPO 2018*.